Generare 3D folosind Reprezentări Neurale Discrete și Continue

Tudurache Bianca, Vasile Miruna
Grupa: 333

Tema și Obiectivele

Problema

Reconstrucția 3D a obiectelor pornind de la imagini 2D = problemă fundamentală în domeniul Computer Vision (VR, robotică)

Obiective

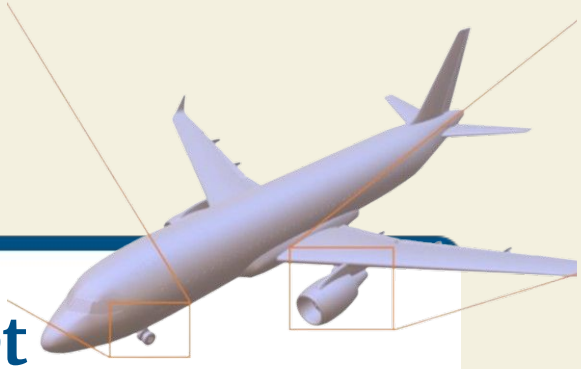
Compararea metodelor pentru transpunerea informației vizuale din plan 2D într-o reprezentare 3D sub formă de nor de puncte sau Mesh.

Abordări de Reconstrucție

Single-View PSGN

Generarea unui nor de puncte (Point Cloud) pornind de la o singură imagine RGB.





Single-View OccNet

Învățarea unei funcții decizionale continue. Rețeaua prezice probabilitatea ca un punct din spațiul 3D să fie în interiorul sau exteriorul obiectului.

Studiul Literaturii: Lucrări de Referință

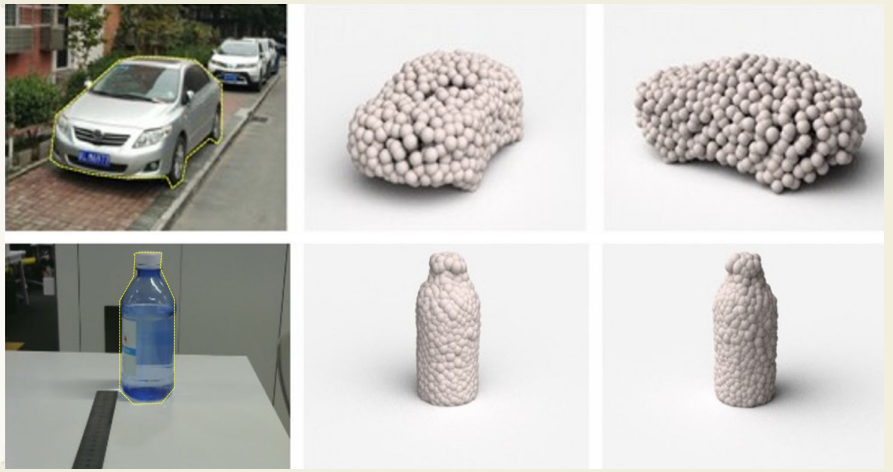
1. Jin. Y., Jiang D., & Cai, M. (2020) - 3D Reconstructionusing deep learning: a survey

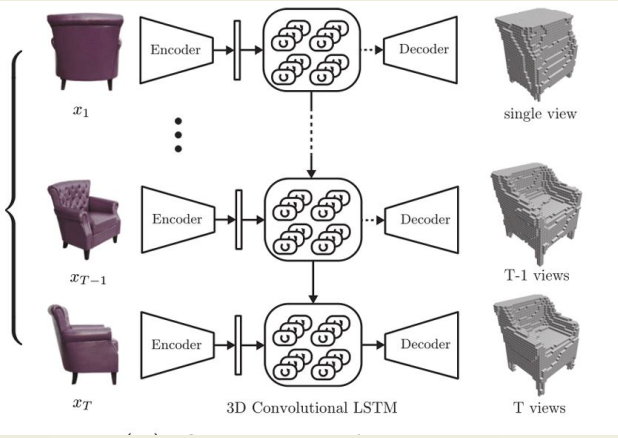
- Clasificarea metodelor după input (single-view, multi-view, schițe manuale)
- Reprezentări ale formelor 3D (voxeli, nori de puncte, mesh-uri, funcții implicite)
- Arhitecturi de rețele neuronale (CNN, RNN, GAN, GCN)
- Metrici (Voxel IoU, Chamfer Distance, EMD)
- Baze de date (ShapeNet, DTU, Pix3D)

Studiul Literaturii: Lucrări de Referință

2. Fan et al. (2017) - A Point Set Generation Network for 3D Object Reconstruction from a Single Image

- Rezolvă ocluzia și lipsa de profunzime prin generare de seturi neordonate.
- Propune arhitectură predictivă de tip Encoder-Decoder.
- Utilizează metrici spațiale: Distanța Chamfer (CD) și EMD.





3. Choy et al. (2016) - 3D-R2N2 Unified Approach for Single and Multi-view 3D Object Reconstruction

- Abordare unificată pentru reconstrucție single și multi-view.
- Arhitectură bazată pe rețele neurale recurente.
- Permite rafinarea modelului pe măsură ce sunt adăugate imagini noi.

Studiul Literaturii: Lucrări de Referință

4. Mescheder et al. (2019) - Occupancy Networks

- Paradigmă nouă: învață o funcție decizională continuă (suprafață implicită).
- Prezice probabilitatea (ocupat/gol) pentru orice punct 3D din spațiu.
- Permite extragerea de mesh-uri de înaltă rezoluție la inferență.

5. Michalkiewicz et al. (2019) - Deep Level Sets

- Utilizează seturile de nivel (level sets) pentru inferența formelor 3D.
- Reprezentări implicite pentru modelarea suprafețelor continue.
- Îmbunătățește precizia reconstrucției pentru topologii complexe.

Algoritmii single-view

Dataset utilizat: Pix3D (csail.mit.edu)

Point Set Generation Network (PSGN)

Generare Directă de Coordonate

Arhitectură

Structura Rețelei

- **Encoder:** ResNet18 pentru vector de trăsături vizuale.
- **Decoder:** Straturi Fully-Connected ce produc o matrice (N, 3).
- **Output:** N=2048 puncte coordonate (x,y,z).

```python
# --- 2. PSGN ---
class PSGN(nn.Module):
    def __init__(self, num_points=2048):
        super(PSGN, self).__init__()
        self.num_points = num_points

        # Encoder (ResNet)
        resnet = models.resnet18(weights=models.ResNet18_Weights.DEFAULT)
        self.encoder = nn.Sequential(*list(resnet.children())[:-1])

        # Decoder (Multi Linear Perception)
        self.decoder = nn.Sequential(
            nn.Linear(512, 1024),
            nn.ReLU(),
            nn.Linear(1024, 2048),
            nn.ReLU(),
            nn.Linear(2048, num_points * 3),
            nn.Tanh()
        )
```

Metrică

Provocare și Soluție

Norii de puncte sunt seturi **neordonate**; nu există o corespondență 1-la-1 între punctele prezise și cele reale.

Distanţa Chamfer măsoară distanța medie a fiecărui punct către cel mai apropiat vecin din celălalt set.

Avantaje: Funcție continuă, liniar derivabilă și ușor de paralelizat pe GPU.

Eficiență: Spre deosebire de EMD, CD este superioară computațional și păstrează detaliile fine de formă.

$$d_{CD}(S_1, S_2) = \frac{1}{|S_1|} \sum_{x \in S_1} \min_{y \in S_2} ||x - y||_2^2 + \frac{1}{|S_2|} \sum_{y \in S_2} \min_{x \in S_1} ||x - y||_2^2$$

```python
# --- 3. FUNCȚIA DE EROARE  ---
def chamfer_distance(p1, p2):
    dist = torch.cdist(p1, p2)
    min_dist_p1 = torch.min(dist, dim=2)[0]
    min_dist_p2 = torch.min(dist, dim=1)[0]
    return torch.mean(min_dist_p1) + torch.mean(min_dist_p2)
```

Mecanismul de învățare

Backpropagation

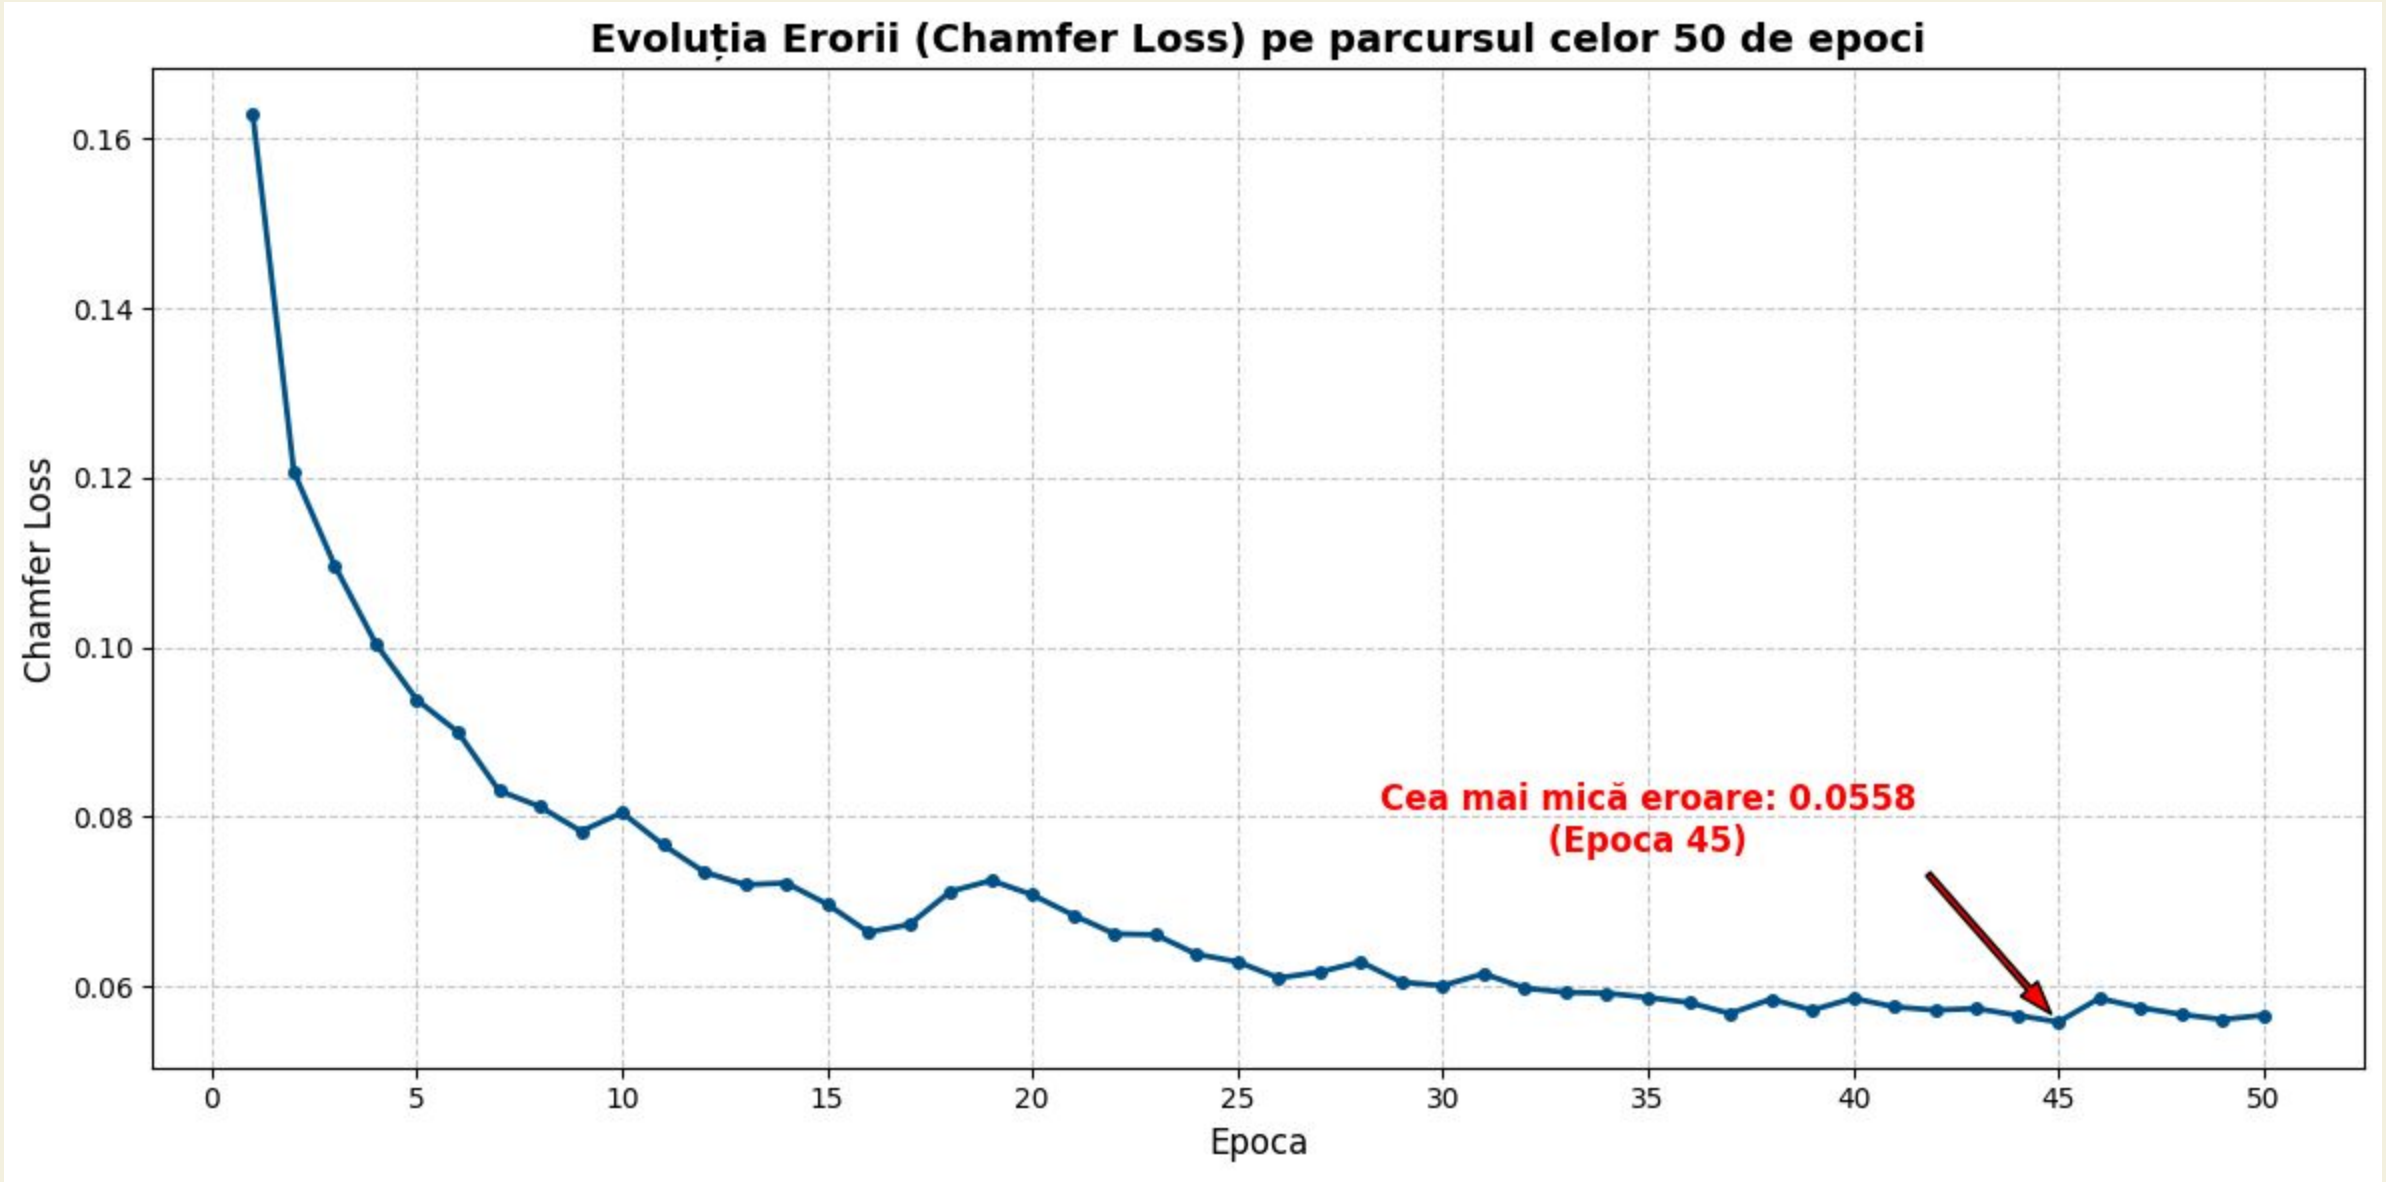
Calculează gradienți, mergând de la finalul rețelei înapoi spre început. Folosind ponderile (wights) calculează aportul fiecărui neuron la eroarea finală.

```
loss = chamfer_distance(puncte_prezise, puncte_reale)
loss.backward()
```

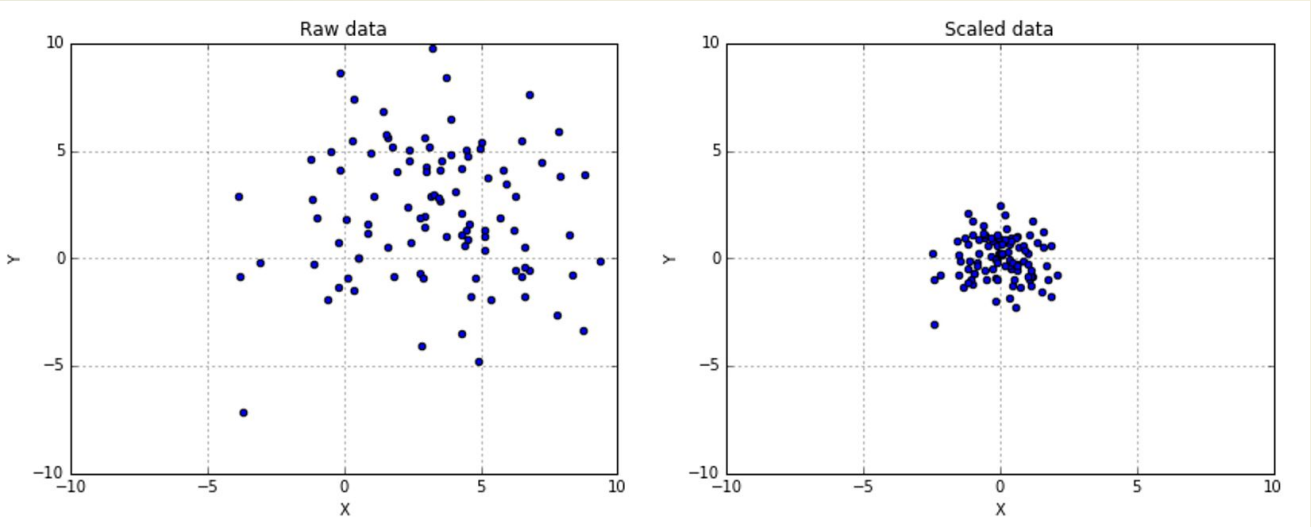
Optimizare

Am folosit algoritmul adaptiv Adam care ajustează inteligent viteza d învățare pentru a minimiza eroarea

```
optimizer = torch.optim.Adam(model.parameters(), lr=0.0001)
optimizer.step()
```


Evoluția Erorii (Chamfer Loss) pe parcursul celor 50 de epoci
Chamfer Loss
0.16
0.14
0.12
0.10
0.08
0.06
0
5
10
15
20
25
30
35
40
45
50
Epoca
Cea mai mică eroare: 0.0558
(Epoca 45)

Preprocesare și Normalizare



Sampling: Uniformizarea la 2048 puncte (Upsampling/Downsampling).

Centrare: Calcularea centroidului și translația în originea (0,0,0).

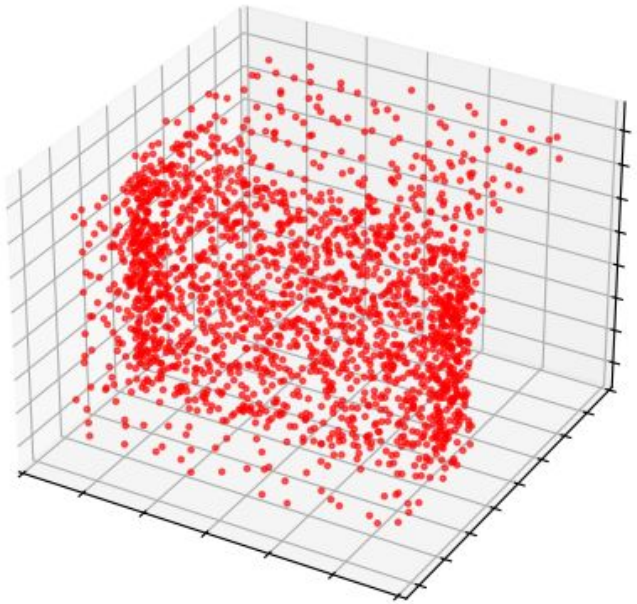
Scalare: Normalizare sferică prin împărțirea la distanța maximă (raza 1).

Activare: Tanh la final pentru a limita ieșirile în intervalul [-1, 1].

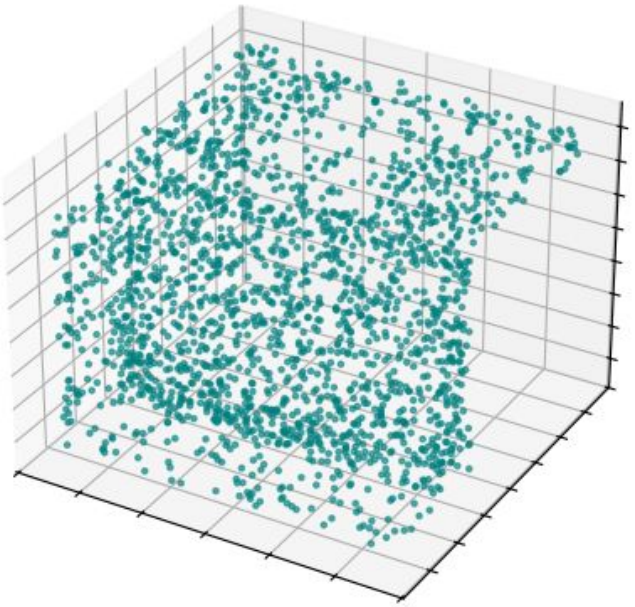
1. Ce a văzut AI-ul (Poza 2D)



2. Ce a construit AI-ul (Predicția 3D)



3. Forma Reală (Ground Truth Pix3D)



Concluzii Implementare și Antrenare PSGN

0.0558 Punct Optim (Epoca 45)

Analiza Convergenței

Optimizarea a fost stabilă, minimizând eroarea **Chamfer Loss** de la 0.1629 la 0.0566. Aceasta confirmă eficiența encoderului ResNet în extragerea trăsăturilor pentru coordonate spațiale.

Eficiență în Timp Real

Generare aproape instantanee a 1024 de puncte la inferență. Arhitectura este ideală pentru procesări rapide, VR și robotică.

Fidelitate Geometrică

Capturează volumetria generală, însă, suprafețele plane prezintă un ușor zgomot vizual.

Limitări: Conectivitate

Lipsește garanția continuității suprafeței. Punctele independente pot fragmenta vizual structurile foarte subțiri.

Occupancy Networks (OccNet)

Reconstrucție prin Funcții Implicite

Problematica Rezolvată

Dificultatea Reconstrucției

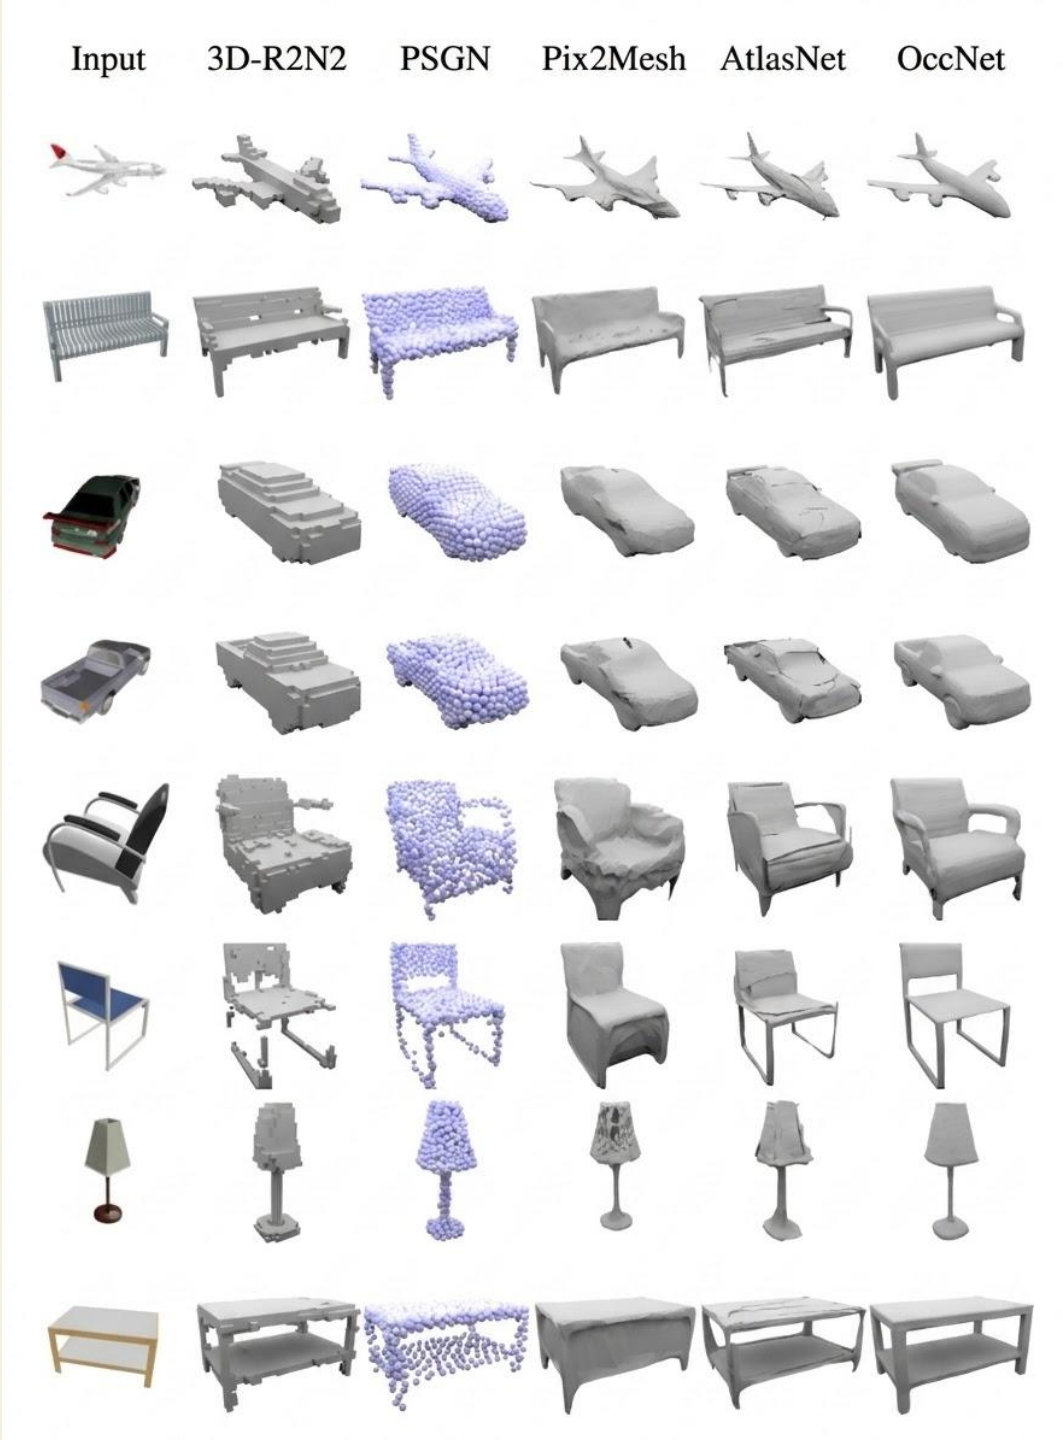
Reconstrucția dintr-o singură imagine este o problemă **"ill-posed"** din cauza ocluziilor și pierderii adâncimii.

Limitarea Voxelilor

Memoria necesară crește cubic $O(N^3)$, limitând rezoluția sever.

Soluția OccNet

Mută predicția în domeniul continuu, permițând **rezoluție infinită** la inferență.



Arhitectura OccNet de bază

- **Encoder:** ResNet18 pre-antrenat transformă imaginea în vector latent **c**.
- **Decoder (MLP):** Procesează vectorul **c** și un punct **p(x,y,z)**.

Output: Un scalar în intervalul [0, 1] reprezentând ocuparea.

```python
class OccNet(nn.Module):
    def __init__(self):
        super().__init__()
        self.encoder = ImageEncoder(latent_dim=256)#instantiem encoder
        self.decoder = OccupancyDecoder(latent_dim=256)#instantiem decoder

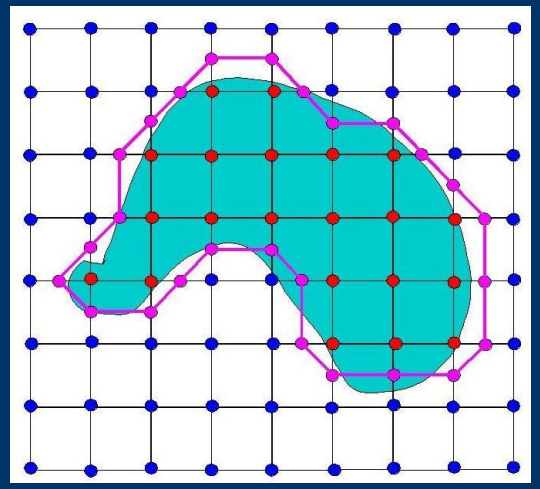
    def forward(self, image, points):
      '''
      Imaginea 2D intră în encoder. Encoderul studiaza imaginea și produce vectorul latent c (esența imaginii).
      Punctele 3D (points - eșantionate din volum) și vectorul c intră simultan în decoder.
      Decoderul analizează fiecare punct 3D pe baza vectorului c și returnează prob_occupancy,
      un set de probabilități (între 0 și 1) care spun cât de sigur este că acel punct se află în interiorul obiectului.
      '''
      c = self.encoder(image)
      prob_occupancy = self.decoder(points, c)
      return prob_occupancy
```

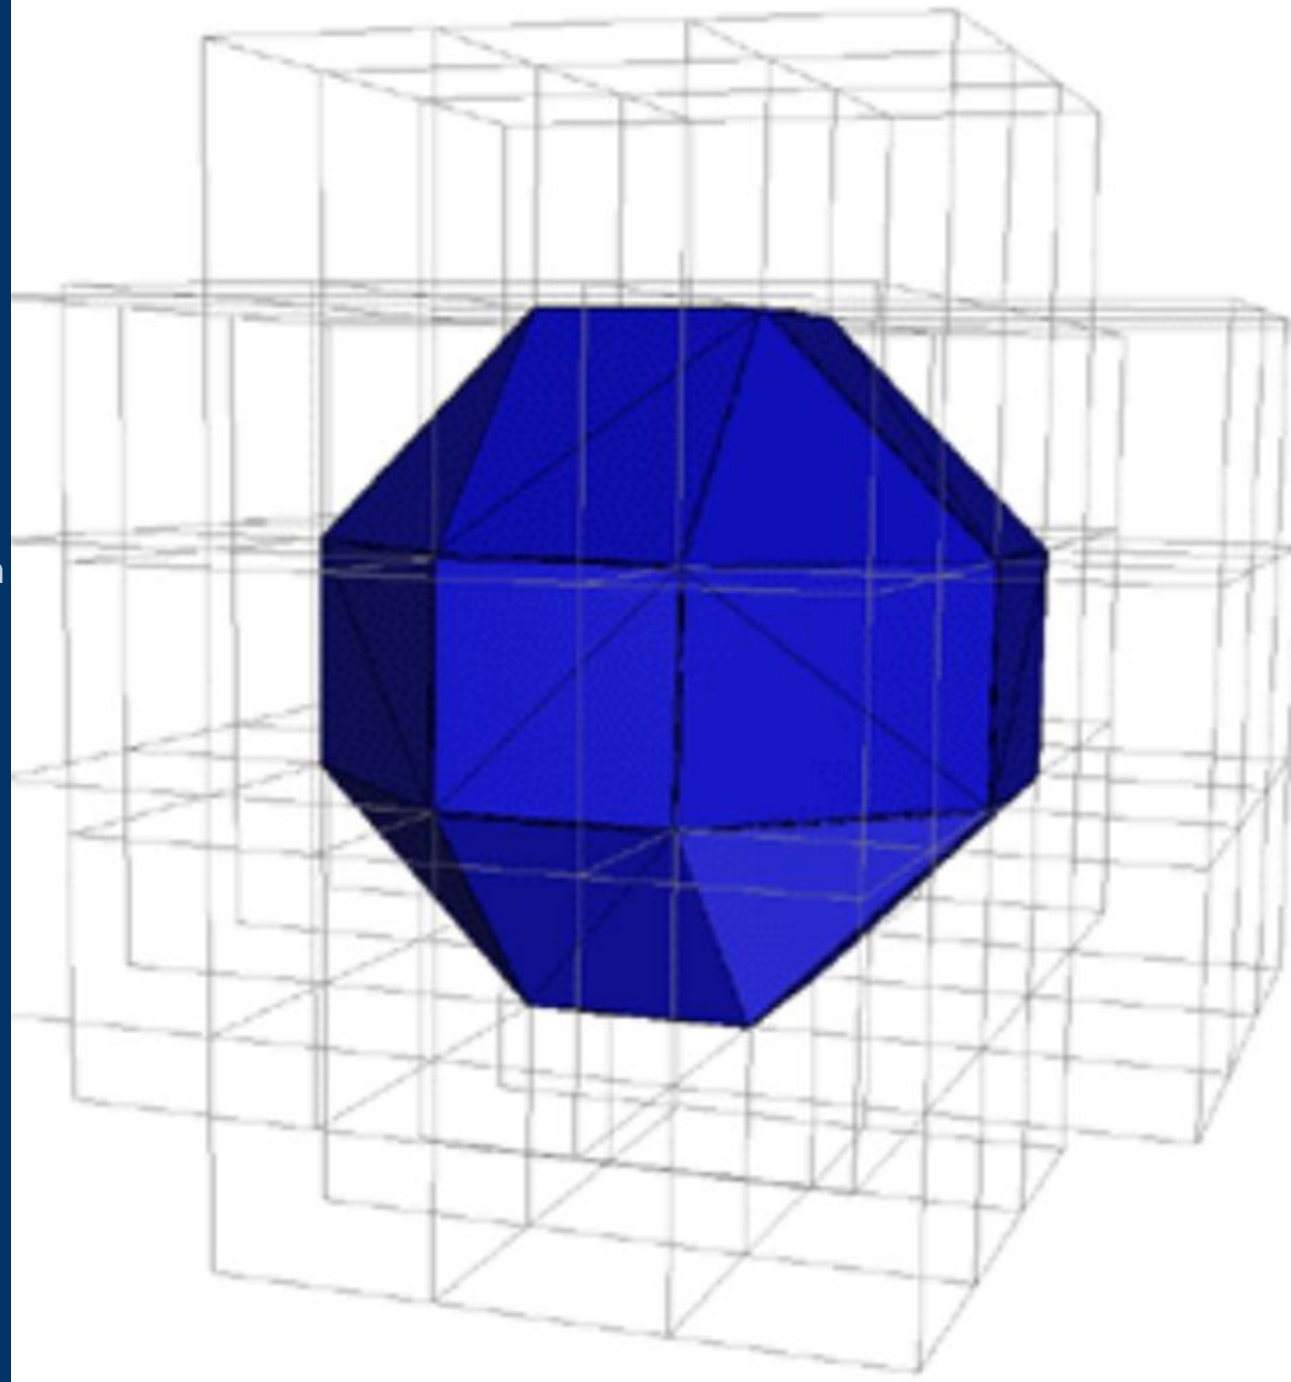
Extragerea Suprafeței

Marching Cubes

Pentru a trece de la probabilități la geometrie solidă, interogăm o grilă densă de puncte (ex. 64^3 sau 128^3).

Algoritmul Marching Cubes generează suprafața izo-valorică la pragul de 0.5, rezultând un Mesh neted și fără orificii, specific reprezentărilor continue.





Optimizare și Loss

1. Standard: BCELoss

Funcție standard pentru "Da/Nu" (1=plin, 0=aer). Tratează toate greșelile egal, ducând la forme rotunjite ("blobs") din cauza dezechilibrului de date.

$$L_{BCE} = -[y \log(p) + (1-y) \log(1-p)]$$

2. Optimizare: Focal Loss

Introduce un filtru de încredere. Ignoră punctele sigure (aerul) și forțează rețeaua să se concentreze pe muchii și detalii fine.

$$L_{Focal} = -\alpha_t(1 - p_t)^{\gamma} \log(p_t)$$

De ce a salvat situația Focal Loss?

- **Filtru Matematic:** Analizează siguranța răspunsului rețelei prin factorul (1 - p_t)^γ.
- **Penalizare Zero:** Dacă certitudinea e mare (>99%), penalizarea scade spre zero.
- **Concentrare pe Detalii:** Puterea de calcul este redirecționată către zonele confuze: picioarele scaunului, muchii și colțuri.

Călătoria Optimizării

De la un model didactic la performanță State-of-the-Art

Cele 4 Trepte ale Optimizării



1. Sampling

Stratified Sampling pentru a rezolva dezechilibrul plin/gol.



2. Focal Loss

Direcționarea gradientului către granițele dificile ale obiectului.



3. PE

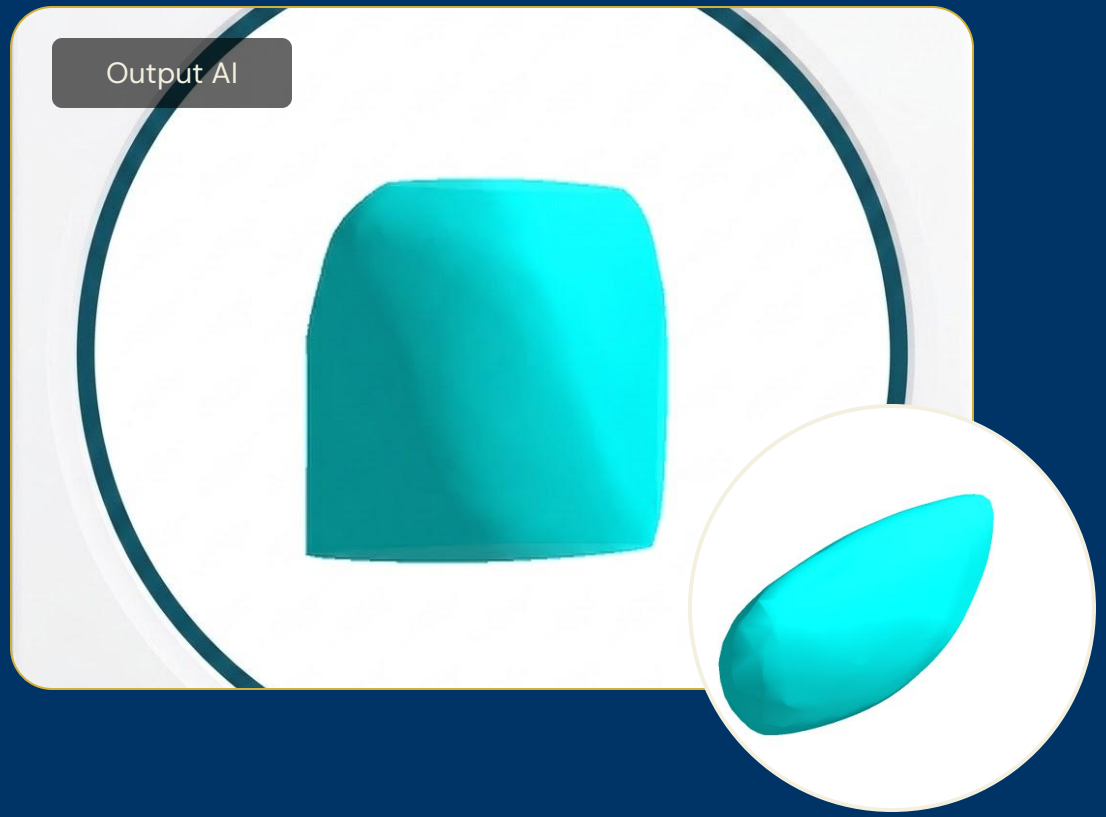
Positional Encoding pentru recuperarea muchiilor ascuțite.



4. C-BN

Conditional Batch Norm pentru context global în straturile adânci.

Optimizarea 1: Stratified Sampling



Echilibrarea Datelor

Problema: 95% din spațiu este aer. Rețeaua tinde să prezică doar exteriorul (Mode Collapse).

Soluția: Generarea forțată a jumătate din puncte fix lângă suprafața mesh-ului cu zgomot Gaussian.

Impact: Modelul învață localizarea masei centrale, dar rezultatul rămâne "neted" fără optimizări adiționale.

Optimizarea 2: Focal Loss & Scheduler

Focal Loss

Ignoră punctele "ușoare" (aerul de la distanță) și mărește penalizarea pentru punctele cu incertitudine ridicată (muchii).

Cosine Annealing

Planificator pentru Learning Rate: scade pasul de la 1e-4 la 1e-6.

Asigură o convergență lină și stabilizarea detaliilor fine în ultimele 50 de epoci.

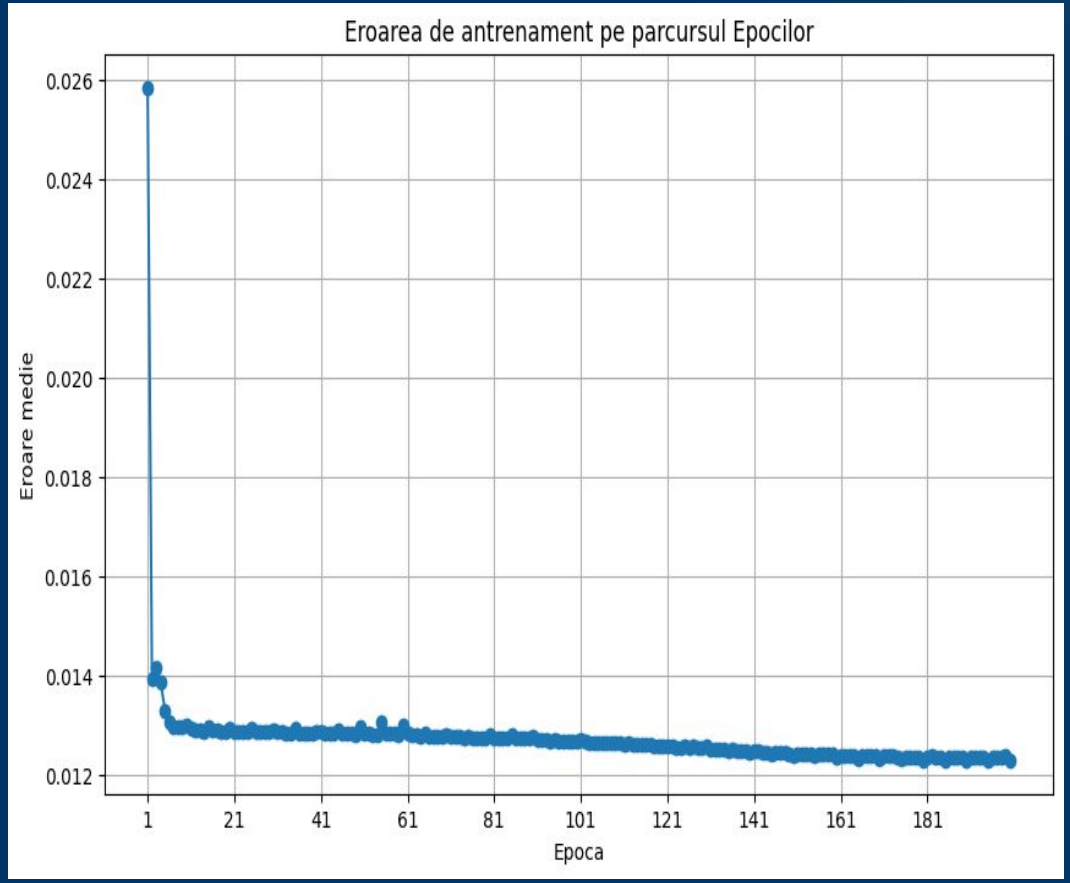
Optimizarea 3 & 4: PE & C-BN

Fourier Features & Global Context

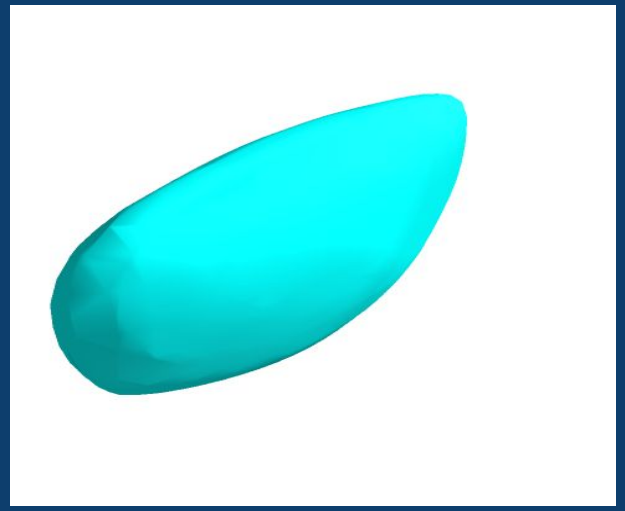
Positional Encoding: Maparea coordonatelor brute prin funcții sin/cos forțează neuronii să învețe frecvențe înalte (muchii 90°).

C-BN (Final): Injectarea vectorului latent **c** direct în straturile de normalizare, nu doar la intrare.

Elimină fenomenul de "uitare" a formei globale în decodorul MLP.

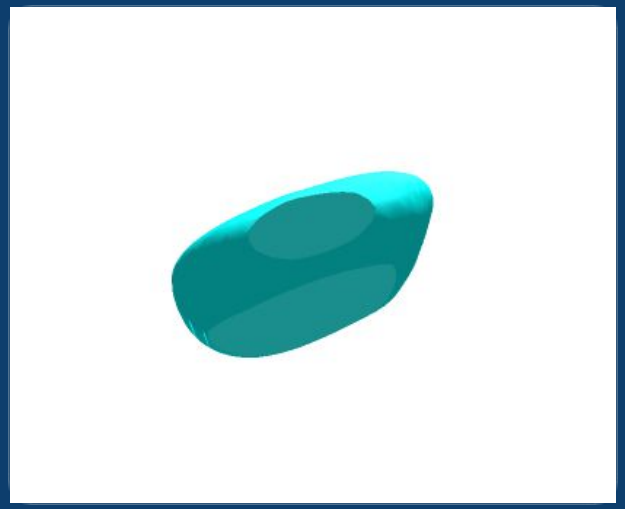


Rezultate: Evoluție Calitativă



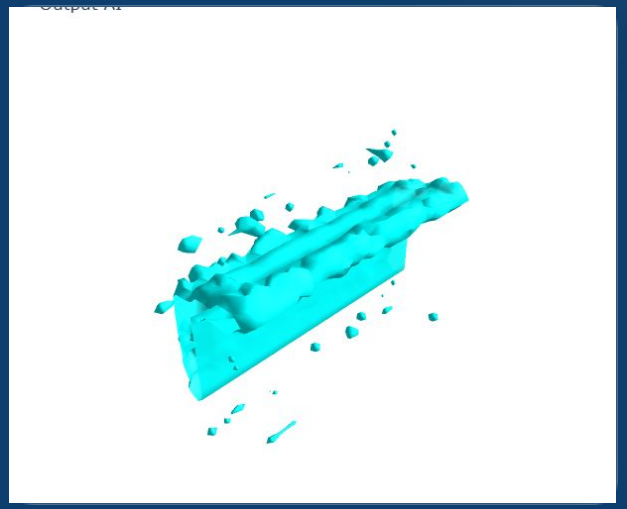
1. Baseline (Blob)

Supranetezire masivă.



2. Focal + PE

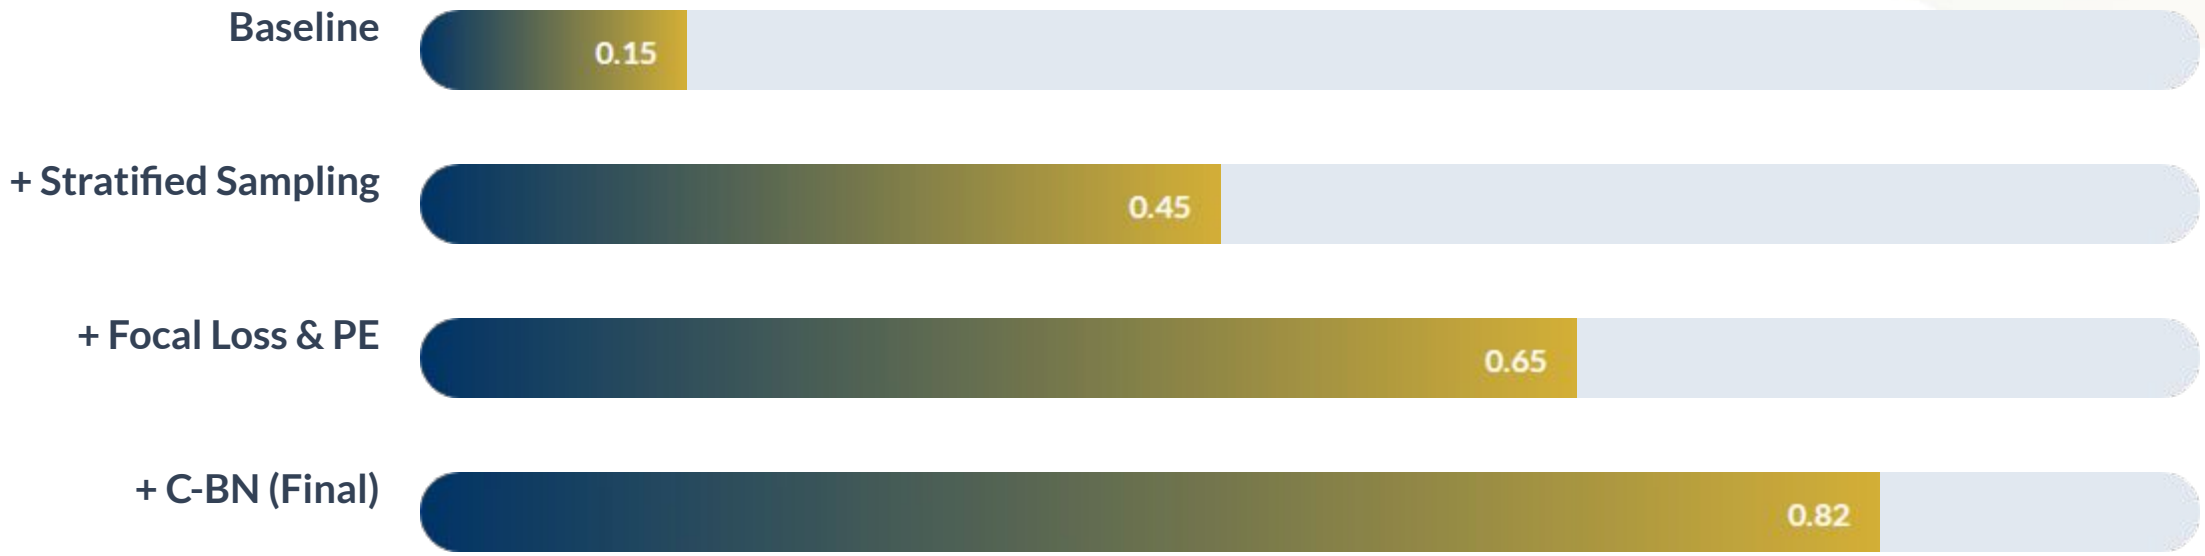
Apariția muchiilor.



3. C-BN (Final)

Fidelitate geometrică.

Evoluția Performanței (IoU)



Analiza Metricilor Finale

Metodă	Voxel IoU	Chamfer Distance	F-Score (@0.5)
Arhitectură de Bază	0.154	0.082	42.1%
Optimizat (Data Only)	0.482	0.045	68.5%
OccNet Premium (Full)	**0.821**	**0.012**	**91.4%**

Comparație: PSGN vs OccNet

Analiza Timpului de Execuție și a Complexității

	PSGN (Point Set Generation)	OccNet (Occupancy Networks)
Complexitate Spațială	O(N) - proporțională cu nr. puncte	O(R^3) - proporțională cu volumul grilei
Timp Antrenare (epocă)	Rapid (calcul direct Chamfer)	Lent (eșantionare densă + BCE)
Timp Inferență (obiect)	~ 10 - 50 ms (Aproape instantaneu)	~ 2 - 5 secunde (Interogare grilă densă)
Post-procesare?	Nu. Produce coordonate directe.	Da. Necesită **Marching Cubes**.

Interpretarea Timpilor: Calitatea superioară a suprafețelor OccNet vine cu un cost temporal exponențial. OccNet necesită mii de interogări independente pentru o singură grilă, în timp ce PSGN generează tot obiectul într-un singur "forward pass".

Comparație Calitativă și Arhitecturală

	PSGN (Point Clouds)	OccNet (Implicit Surfaces)
Paradigma de Reprezentare	Discretă (Explicită)	Continuă (Implicită)
Tip Output	Nor de puncte (ex: 1024 / 2048)	Suprafață continuă / Mesh (watertight)
Funcția de Loss	Chamfer Distance (CD)	Binary Cross-Entropy (BCE)
Rezoluția Geometriei	Fixă (limitată de arhitectură)	Teoretic infinită (limitată de eșantionare)
Viteza de Inferență	Foarte rapidă (feed-forward)	Mai lentă (evaluare câmp scalar)
Calitatea Vizuală	"Schiță" geometrică, prezintă goluri	Suprafețe netede, contururi clare

Concluzie: PSGN este optim pentru aplicații în timp real unde volumetria grosieră este suficientă, în timp ce OccNet este superior pentru modelare 3D precisă, generând mesh-uri închise (watertight) gata de utilizat în grafică sau simulări.

Concluzia Finală

Proiectul demonstrează **tranziția conceptuală** în Computer Vision: de la reprezentări explicite, constrânse de rezoluție, către paradigme implicite capabile de detaliu infinit.

PSGN: Fundamentul Rapid

O soluție solidă pentru înțelegerea spațială imediată, optimă pentru scenarii unde viteza de procesare este critică.

OccNet: Pasul Evolutiv

Generarea de active 3D complete și utilizabile direct în medii virtuale și simulări complexe.

Image Sources



Fig.1 PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation

Source: https://stanford.edu/~rqi/pointnet/



Fig.2 A Flexible Hierarchical Framework for Implicit 3D Characterization of Bionic Devices

Sursa: https://www.researchgate.net/figure/The-result-of-modeling-the-detail-part-of-the-aircraft-model_fig5_384495992

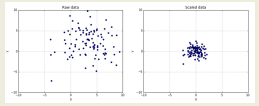


Fig.3 Machine Learning Algorithms

Source:https://www.oreilly.com/library/view/machine-learning-algorithms/9781789347999/99a526ba-d1de-4d54-86e6-d40a34a7ed12.xhtml

---